

모델 변환 및 Node.js 추론

MNIST CNN → .pth / 양자화 .pth / .onnx 변환 + JavaScript 크로스 플랫폼 추론

날짜	모델 선택	언어 환경	평가 데이터셋
2026-03-11	MNIST CNN (LeNet-style)	Python (PyTorch) + Node.js (JavaScript)	MNIST test set (10,000장)

1. 미션 요약

ONNX 추론 정확도 99.09% 기준 95% 이상 ✓ 달성	변환 포맷 수 3종 .pth / 양자화 .pth / .onnx	NODE.JS 추론 대상 3장 image1~8, image2~3, image3~2
--	---	--

MNIST 데이터셋(60,000장)으로 학습한 CNN 모델을 PyTorch `state_dict`, `quantize_dynamic` (INT8), `torch.onnx.export` (opset 11) 으로 변환 저장. Python `onnxruntime` 으로 정확도를 검증하고, 심화 미션으로 Node.js 환경에서 `onnxruntime-node` + `jimp` 를 이용해 이미지 3장 추론을 완료.

2. 추출된 모델 파일 및 용량

포맷	파일명	용량	크기 비교	설명
PyTorch	mission_16_mnist_cnn.pth	1.61 MB 1,690,307 bytes	1.61 MB	PyTorch <code>state_dict</code> 저장 — 기본 float32 가중치
양자화	mission_16_mnist_cnn_quantized.pth	472 KB 483,869 bytes	472 KB	<code>quantize_dynamic</code> INT8 — FC 레이어 양자화, 71% 절감
ONNX	mission_16_mnist_cnn.onnx	14.2 KB 14,590 bytes	14 KB	ONNX 그래프 구조 파일 (opset 11)
ONNX data	mission_16_mnist_cnn.onnx.data	1.66 MB 1,736,704 bytes	1.66 MB	ONNX external data 파일 — 가중치 분리 저장 (대형 모델 대비 호환)

* ONNX 모델 실질 용량 = .onnx + .onnx.data ≈ 1.68 MB | 양자화 효과: 1.61 MB → 472 KB (약 71% 감소)

3. 기본 미션 — Python ONNX 추론 검증

ONNX 모델 추론 결과 총 10,000장 중 9,909장 정답 정확도: 0.9909 (99.09%) ✓ 95% 이상 달성

Inference.ipynb — ONNX 추론 샘플 시각화 (green=correct, red=wrong)	
ONNX Inference Results (green=correct, red=wrong)	
	pred:7 true:7
	pred:2 true:2
	pred:1 true:1
	pred:0 true:0
	pred:4 true:4
	pred:1 true:1
	pred:4 true:4
	pred:9 true:9
	pred:5 true:5
	pred:9 true:9
	pred:0 true:0
	pred:6 true:6
	pred:9 true:9
	pred:0 true:0
	pred:1 true:1
	pred:5 true:5

4. 심화 미션 — Node.js ONNX 추론 결과

Python 없이 JavaScript (Node.js) 환경에서 ONNX 모델을 직접 로드하여 추론. `onnxruntime-node` + `jimp v0.22.x` 를 사용, PNG 이미지를 Float32Array → NCHW 텐서로 변환 후 `argmax`로 예측 레이블 출력.

이미지	예측 결과	처리 파이프라인
image1.png	8	PNG → resize(28×28) → grayscale → Float32Array[784] → Tensor[1,1,28,28] → argmax
image2.png	3	PNG → resize(28×28) → grayscale → Float32Array[784] → Tensor[1,1,28,28] → argmax
image3.png	2	PNG → resize(28×28) → grayscale → Float32Array[784] → Tensor[1,1,28,28] → argmax

터미널 — node inference.js 실행 결과
<pre>(16_Model-conversion) Yucheu1ui-MacBookAir:16_Model-conversion youuchul\$ node inference.js ===== Mission 16 심화 - MNIST ONNX 추론 (Node.js) ===== 모델 : /Users/youuchul/Documents/github/01_deep_learning/16_Model-conversion/data/mnist_cnn.onnx 입력 형태 : input ["input"] image1.png → 예측 : 8 image2.png → 예측 : 3 image3.png → 예측 : 2 추론 완료</pre>

5. 디버깅 및 오류 해결 과정

1 data/models/ gitignore로 인한 모델 파일 미추적 문제 해결됨
문제 상황 .gitignore 에 data/models/ 가 등록되어 있어, 학습 후 생성된 .pth / .onnx 파일들이 git 추적 대상에서 제외됨. git status 에서 모델 파일이 보이지 않아 발견. 원인 대용량 데이터 제외 목적의 gitignore 설정이 모델 파일에도 적용됨. 원래 의도는 data/mnist_data/ (MNIST 원본 데이터, ~11MB)만 제외였으나, 모델 파일이 같은 data/ 하위에 생성되어 함께 무시됨. 해결 방법 .gitignore 에서 data/models/ 라인 제거. data/mnist_data/ 는 유지(대용량 데이터셋). 이후 모델 3종 정상 추적 확인. <pre># 수정 후 .gitignore node_modules/ data/mnist_data/ - MNIST 원본 데이터 (유지) __pycache__/ .ipynb_checkpoints/ *.pyc .DS_Store .venv/ ai_history/code_insights/ - 개인 학습 노트 (신규 추가)</pre>
2 git add 시 gitignore 파일이 스테이징된 문제 해결됨
문제 상황 git add 16_Model-conversion/ 실행 시, ai_history/code_insights/NodeJS_ONNX_Inference.md 가 gitignore 설정에도 불구하고 스테이징 영역에 포함됨. 비공개 학습 노트가 원격 저장소에 노출될 뻔한 상황. 원인 git의 gitignore 동작 원리: git add 로 경로를 명시하면 gitignore 규칙이 우회됨 (git은 명시적 추가를 우선). 새로 생성된 파일에도 동일하게 적용. 해결 방법 git restore --staged 16_Model-conversion/ai_history/code_insights/ 로 스테이징 취소. 이후 해당 경로를 제외하고 커밋 진행. <pre># 스테이징 취소 명령 git restore --staged 16_Model-conversion/ai_history/code_insights/ # 확인 git status → ai_history/code_insights/ 제거 완료 ✓</pre>
3 jimp v1.x vs v0.22.x ESM/CommonJS 호환성 문제 사전 방지
문제 상황 Node.js 환경에서 CommonJS(require()) 방식으로 작성한 코드에서 jimp 를 최신 버전으로 설치하면 다음 오류 발생 가능: Error [ERR_REQUIRE_ESM]: require() of ES Module not supported 원인 jimp v1.x 는 ESM(ES Modules) 전용으로 변경됨. require() 와 호환되지 않으며 import 문법과 함께 사용해야 함. 반면 onnxruntime-node 는 CommonJS 방식으로 동작. 해결 방법 package.json 에 "jimp": "^0.22.12" 로 버전 고정. v0.22.x는 CommonJS require() 완전 지원. <pre># package.json 의존성 "dependencies": { "jimp": "^0.22.12", - CommonJS 호환 버전 고정 "onnxruntime-node": "^1.24.3" } # v1.x 사용 시 오류 예시 Error [ERR_REQUIRE_ESM]: require() of ES Module .../jimp/dist/index.js not supported</pre>

6. 생성 및 수정 파일 목록

modeling.ipynb	MNIST CNN 학습 + 3종 포맷 변환 (기본 미션 1)
inference.ipynb	Python ONNX 추론 정확도 검증 — 99.09% 달성 (기본 미션 2)
inference.js	Node.js ONNX 추론 스크립트 — onnxruntime-node + jimp (심화 미션)
data/models/mission_16_mnist_cnn.pth	PyTorch state_dict 저장 모델 (1.61 MB)
data/models/mission_16_mnist_cnn_quantized.pth	양자화 모델 INT8 — FC 레이어 (472 KB, 71% 절감)
data/models/mission_16_mnist_cnn.onnx (+.onnx.data)	ONNX 변환 모델 opset 11 (총 ~1.68 MB)
.gitignore	data/models/ 제거 (모델 파일 추적), ai.history/code.insights/ 추가 (개인 노트 제외)
study-notes/NodeJS_JavaScript.md	Node.js/JS 기초 개념 + 프로젝트 코드 패턴 (신규)
README.md	폴더 구조·실행 순서·모델 파일·학습노트 최종 정리